Лекция 2. Введение в статистику. Организация статистического исследования

Часть 1. Генеральная совокупность и выборка

Генеральная совокупность (population)

Это **все объекты/люди/события**, про которые мы хотим сделать вывод.

Примеры:

- все жители России (если изучаем доходы населения);
- все студенты конкретного вуза (если изучаем успеваемость);
- все продажи магазина за год (если изучаем спрос).

Главная идея: **вывод должен относиться именно к этой “большой группе”**, даже если мы её целиком не измеряем.

Выборка (sample)

Это **часть генеральной совокупности**, которую мы реально собрали и анализируем.

Примеры:

- 1000 человек, которых опросили про доход;
- оценки 200 студентов из всех курсов;
- 500 чеков, случайно выбранных из всех продаж.

Зачем нужна выборка? (чуть расширим смысл)

Потому что генеральная совокупность часто:

- слишком большая (миллионы людей);
- дорогая для измерения;
- частично недоступна;
- может меняться во времени (пока соберёшь всех — условия уже другие).

Идеальный сценарий: выборка **репрезентативна**, то есть достаточно хорошо отражает структуру генеральной совокупности (по возрасту, полу, регионам и т.д.), чтобы по ней можно было судить о “всех”.

Наблюдательное исследование (observational study) — это сбор данных без вмешательства: исследователь ничего специально не меняет, а лишь фиксирует значения переменных (variables) и анализирует связи между ними.

Эксперимент (experiment) — это исследование с вмешательством: исследователь целенаправленно изменяет фактор/условие (treatment) и смотрит, как это влияет на результат (response/outcome).

Ключевая разница:

- наблюдательное исследование (observational study) обычно позволяет говорить о связи/ассоциации (association, correlation), но не гарантирует причинность (causation);
- эксперимент (experiment), при правильной организации, позволяет делать выводы о причинно-следственном влиянии (cause-and-effect).

Пример логики:

- observational study: «люди, которые занимаются спортом, реже болеют» — это связь, но причины могут быть смешаны (например, возраст, питание, доход);
- experiment: «мы случайно разделили людей на группы, одной дали программу тренировок (treatment group), другой нет (control group), и сравнили результат» — так проще обосновать причинность.

Перепись и выборочное исследование

Перепись (census) — это наблюдательное исследование, где изучают **каждый** элемент генеральной совокупности.

Выборочное исследование / выборочный опрос (sample study / sample survey) — это наблюдательное исследование, где анализируют **часть** генеральной совокупности, то есть выборку (**sample**).

Почему перепись часто проблемна (problems of a census)

1. **Дорого и долго.**
2. **Вся совокупность может быть недоступна (the whole population may be not available).**
   Пример: нельзя протестировать лекарство "на всех", часть людей не болеет, часть недоступна и т.д.
3. **Измерение может уничтожать объект (destructive testing).** Пример: чтобы узнать срок службы детали, её нужно довести до отказа.
4. **Ошибки исполнителей (errors due to poor qualification of personnel).** Чем масштабнее проект, тем выше риск организационных и человеческих ошибок.

Методы отбора выборки (sampling methods)

1) Простая случайная выборка (simple random sampling, SRS)

Простая случайная выборка (SRS) — это способ отбора, при котором **каждая возможная выборка** фиксированного размера n имеет **одинаковую вероятность** быть выбранной из генеральной совокупности N.

Практический смысл: если в совокупности есть список всех элементов (sampling frame), то мы как будто "перемешали" этот список и случайно выбрали n элементов без систематического предпочтения.

Почему SRS важна:

- она даёт наиболее "чистую" статистическую модель: наблюдения можно рассматривать как случайные величины $X_1, \dots, X_n$ и применять стандартные методы оценивания;
- минимизирует систематические перекосы (bias), если отбор действительно случайный.

Проблемы SRS (limitations of SRS):

1. Нужен полный список элементов совокупности (sampling frame), а его часто нет или он неполный. Пример: “все покупатели магазина за месяц” — это поток людей, и заранее полного списка нет.

2. Может быть очень дорого собирать данные, если элементы “разбросаны” по территории.
   Пример: случайно выбранные респонденты могут оказаться в разных городах/районах — логистика становится тяжёлой.

3. Возможна проблема неответов (nonresponse): даже если отобрали случайно, часть людей может отказаться, и выборка перестаёт быть “идеальной”.

Пример:

Пусть есть Кирилл. Он ищет себе запчасти на BMW E36. Генеральная совокупность (population) — все объявления о нужной ему запчасти на Avito, Drom, профильных форумах и в разборках за последний месяц. Кирилл делает список (sampling frame) из 200 таких объявлений и с помощью генератора случайных чисел выбирает 30 объявлений без “любимчиков” и без правил типа «первые в выдаче». Эти 30 объявлений — простая случайная выборка (SRS): каждое объявление имело одинаковый шанс попасть в выборку. Дальше он по этой выборке оценивает типичную цену (mean/median price) и разброс цен (variability), чтобы понять, сколько реально стоит запчасть и где его пытаются “развести”.

2) Систематическая выборка (systematic sampling)

Идея: выбираем случайную стартовую точку (random start), а дальше берём **каждый** $\boldsymbol{k}-$ й элемент.

Пример: опрос в супермаркете — случайно выбрали первого покупателя, потом опрашиваем каждого 10-го входящего.

Плюсы:

- проще и быстрее в реализации;
- часто не нужен полный список заранее.

Риск:

- если в данных есть периодичность (periodicity), которая совпадает с шагом k, можно получить смещение (bias).
- Пример: если каждый 10-й — это “группа студентов одной пары”, а мы берём каждого 10-го в журнале, то можем случайно переотбирать определённый тип людей.

3) Стратифицированная выборка (stratified sampling)

Стратифицированная выборка (stratified sampling) — это способ отбора, где генеральную совокупность (**population**) сначала делят на несколько непересекающихся групп — **страт (strata)**, а затем из каждой страты отдельно берут выборку.

Логика простая: если внутри каждой страты объекты более “похожи” друг на друга, чем вся совокупность в целом, то оценки получаются **точнее**.

Как делается (algorithm):

1. Разбиваем совокупность на K страт (strata) по важному признаку: пол, возраст, курс, регион, тип клиентов и т.д.
2. В каждой страте k делаем случайный отбор (часто SRS) размера n_k.
3. Склеиваем всё вместе: общая выборка $n = \sum_{k=1}^{K} n_k$.

Как выбирать размеры n_k (allocation):

- **Пропорциональная стратификация (proportional allocation):** n_k берут пропорционально размеру страты N_k: чем больше страта, тем больше из неё наблюдений.
- **Непропорциональная (disproportional allocation):** некоторые страты намеренно “перебирают” (oversample), чтобы надёжнее оценить малые, но важные группы.

Плюсы стратификации (advantages):

- **выше точность (precision)** при том же объёме n, потому что уменьшается случайный шум внутри групп;
- гарантируется представительство всех ключевых подгрупп (representation), то есть меньше риск, что важная группа “случайно не попала”;
- удобно сравнивать страты между собой (comparisons across strata), например: сравнить мужчин/женщин, регионы, курсы.

Типичная ошибка: Страты должны быть **взаимоисключающими и исчерпывающими (mutually exclusive and collectively exhaustive)**: каждый элемент совокупности должен попасть ровно в одну страту.

4) Кластерная выборка (cluster sampling)

Кластерная выборка (cluster sampling) — это способ отбора, при котором генеральную совокупность делят на группы **кластеров (clusters)**, случайно выбирают некоторые кластеры, и уже внутри них собирают данные.

Ключевая идея: кластеры выбирают так, чтобы **удешевить и упростить сбор данных** (logistics/cost reduction). Часто кластеры — это естественные "единицы" вроде школ, классов, домов, районов, предприятий.

Как делается (basic idea):

1. Разбиваем совокупность на кластеры (clusters).
2. Случайно выбираем часть кластеров.
3. Дальше есть два типичных варианта:

- **Одноступенчатая кластерная выборка (one-stage cluster sampling):** берём **всех** элементов внутри выбранных кластеров.
- **Двухступенчатая (two-stage cluster sampling):** внутри выбранных кластеров дополнительно берём выборку элементов (обычно SRS).

Пример:
Хотим оценить средний балл школьников города.

- Страты: делить по типу школы (гимназии/обычные) и выбирать из каждой — это про точность.
- Кластеры: выбрать случайно 10 школ (кластеры) и опросить всех/часть учеников в них — это про дешевизну.

Важно: чем кластеры отличаются от страт (clusters vs strata)

Стратификация (stratified sampling):

- цель — **повысить точность**;
- в каждой страте обычно делают случайный отбор;
- страты стараются делать **однородными внутри** (homogeneous within strata), но **разными между собой**.

Кластеризация (cluster sampling):

- цель — **снизить стоимость/сложность сбора**;
- выбирают не отдельных людей, а целые "пачки" (clusters);

- кластеры часто стараются делать **похожими друг на друга** (каждый кластер как “маленькая копия” совокупности), но на практике внутри кластера наблюдения бывают похожи ⇒ точность может падать.

Минус кластерной выборки (main drawback)

Наблюдения внутри кластера часто **сильно похожи** (intra-cluster correlation), поэтому эффективной информации меньше, чем при SRS того же объёма. То есть кластерная выборка обычно дешевле, но статистически “слабее” при равном n.

5) Многоступенчатая выборка (multistage sampling)

Многоступенчатая выборка (multistage sampling) — это расширение кластерной идеи: отбор делается **в несколько этапов**, где на каждом этапе выбираются более “мелкие” единицы.

Обычно это выглядит так:

1. сначала выбираем крупные единицы (primary sampling units, PSU): регионы, города, районы;
2. внутри них выбираем более мелкие (secondary sampling units, SSU): кварталы, дома, школы;
3. затем уже выбираем конечные элементы (ultimate sampling units): людей, студентов, товары и т.д.

Зачем это нужно:

- когда нет полного списка всех элементов совокупности, но есть списки “уровнями” (например, список регионов есть, а список всех жителей — нет);
- чтобы резко упростить логистику и снизить стоимость;
- чтобы адаптироваться к реальной структуре объектов (страна → регион → город → дом → человек).

Пример (соцопрос):

- 1-я ступень: случайно выбираем 20 районов города;
- 2-я ступень: в каждом районе выбираем по 10 домов;
- 3-я ступень: в каждом доме выбираем 1–2 квартиры;
- 4-я ступень: в квартире выбираем 1 человека по правилу (например, “последний день рождения”).

Это и есть многоступенчатый дизайн (sampling design).

Комбинации методов (combined designs)

На практике методы часто смешивают:

- сначала **стратифицируют** (stratify) по важному признаку (например, регионы/типы населённых пунктов),
- затем внутри каждой страты делают **кластерный** или **многоступенчатый** отбор.

Так делают, потому что нужно одновременно:

- обеспечить представительство важных групп (representation),
- и удержать стоимость/время в разумных пределах (cost/time).

Ошибки и смещения в статистическом исследовании

Когда мы делаем выводы по выборке (sample) о генеральной совокупности (population), важно понимать: данные могут “врать” по двум причинам.

1. из-за случайности отбора — даже при идеальном дизайне;
2. из-за систематических ошибок — когда исследование устроено так, что результат уводит в сторону.

1) Ошибка выборки (sampling error)

Ошибка выборки (sampling error) — это естественная случайная погрешность, возникающая потому, что мы смотрим не на всю совокупность, а только на часть.

Даже если выборка случайная и честная (SRS), разные случайные выборки дадут чуть разные оценки.

Например, средний доход по одной выборке будет 61 тыс., по другой — 58 тыс., по третьей — 63 тыс. Это нормально.

Важно:

- sampling error **уменьшается**, если увеличивать размер выборки n;
- sampling error можно оценивать статистически (standard error, confidence interval).

2) Смещение (bias)

Смещение (bias) — это систематическая ошибка, когда выборка или измерение устроены так, что результат стабильно “кривой” в одну сторону.

Главный момент:

- sampling error — “шум” вокруг истины;
- bias — “сдвиг” от истины.

Если есть сильное bias, то увеличение n не спасает: мы получим очень “точную”, но неправильную оценку.

Источники смещения (sources of bias)

2.1 Смещение отбора (selection bias / undercoverage)

Смещение отбора (selection bias) возникает, когда часть совокупности систематически не попадает в выборку или имеет меньший шанс быть отобранной.

Классика:

- опрос “по телефону” исключает людей без телефона;
- онлайн-опрос исключает людей без интернета;
- опрос только в рабочее время исключает тех, кто работает сменами.

Термин: **неполный охват (undercoverage)** — когда sampling frame не покрывает всю population.

2.2 Смещение неответов (nonresponse bias)

Смещение неответов (nonresponse bias) — когда часть выбранных людей не отвечает, и это связано с изучаемой темой.

Пример:

- люди с очень высоким доходом чаще отказываются сообщать доход;
- недовольные сотрудники чаще игнорируют анкеты от работодателя.

Итог: ответы остаются “от специфических людей”, и статистика уезжает.

2.3 Смещение из-за формулировки вопросов (response bias / wording effect)

Смещение ответа (response bias) — люди отвечают не так, как есть, из-за давления, формулировки или контекста.

Примеры:

- “Вы же поддерживаете полезную реформу?” — вопрос уже подталкивает;
- социально желательные ответы (social desirability): люди завышают “хорошее” и занижают “плохое”.

2.4 Ошибка измерения (measurement error)

Ошибка измерения (measurement error) — проблема не в том, кого мы отобрали, а в том, как измерили переменную.

Примеры:

- весы “врут”;
- респондент неправильно помнит расходы;
- разные интервьюеры по-разному объясняют вопрос;
- данные вводятся с ошибками (data entry error).

2.5 Ошибка обработки/анализа (processing error)

Ошибка обработки (processing error) — ошибки кодирования, очистки, объединения таблиц, построения показателей.

Примеры:

- перепутали единицы измерения;

- неверно обработали пропуски;
- “случайно” удалили часть наблюдений;
- неправильно посчитали агрегаты.

Как снизить ошибки (how to reduce errors) — практическая логика

- уменьшать sampling error: увеличивать n, делать стратификацию (stratified sampling);
- бороться с bias: хороший sampling frame, контроль неответов, нейтральные формулировки, пилотный опрос (pilot study), стандартизация измерения (standardization).

Эксперимент (experiment)

Эксперимент (experiment) — это исследование, в котором исследователь **целенаправленно изменяет** условия и наблюдает, как это влияет на результат. Цель — получить основания говорить о **причинно-следственной связи (causation)**, а не только о связи (association).

Основные элементы эксперимента (key components)

Экспериментальные единицы (experimental units) — объекты, на которых проводится эксперимент: люди, детали, участки дороги, группы студентов и т.д.

Фактор / объясняющая переменная (factor / explanatory variable) — то, что мы изменяем или контролируем.
Пример: метод обучения, тип топлива, дозировка препарата.

Отклик / результат (response variable / outcome) — то, что измеряем в конце и сравниваем между условиями.
Пример: балл на экзамене, расход топлива, давление.

Лечения / воздействия (treatments) — конкретные варианты фактора.
Пример: метод A vs метод B; дозировка 0 мг, 5 мг, 10 мг.

Контрольная и экспериментальная группы (control group / treatment group)

Контрольная группа (control group) — группа без воздействия или со стандартным воздействием (baseline / standard treatment). Нужна, чтобы понимать, что происходит “само по себе”, без нового фактора.

Экспериментальная группа (treatment group) — группа, которая получает новое воздействие (treatment).

Почему важна рандомизация (randomization)

Рандомизация (randomization) — случайное распределение экспериментальных единиц по группам/лечениям.

Зачем:

- выравнивает скрытые различия (confounders) между группами “в среднем”;
- снижает риск систематического смещения (bias);
- делает сравнение групп более честным.

Пример: если “сильных студентов” случайно отправить в одну группу, мы перепутаем эффект метода обучения с эффектом уровня подготовки. Рандомизация снижает вероятность такого перекоса.

Примеры экспериментов (examples)

1. Схема оплаты продавцов (salesmen compensation scheme)
   Вопрос: что лучше стимулирует продажи — процент $p\%$ от объёма продаж (commission) или бонус, если продал больше, чем x (bonus if sales exceed x)?
2. Скидки на товары (discount on products)

   Вопрос: что даст больший рост спроса — скидка 50% (50% off) или акция «2 по цене 1» (2-for-1)?
3. Медицинские исследования (medical studies)

   Вопрос: какое лекарство от гриппа эффективнее (which flu medicine is more effective)?

Части эксперимента (parts of an experiment)

1. Экспериментальные единицы (experimental units) Объекты, на которых проводят эксперимент. Если это люди — их часто называют участниками (participants).
2. Объясняющие переменные / факторы (explanatory variables / factors / independent variables). Это то, чем управляет исследователь (manipulated variables).
3. Отклик / результат (response variable / dependent variable)

   Это то, что измеряют как итог воздействия (outcome).
4. Воздействия / «лечения» (treatments)

   Это конкретные комбинации факторов, которые сравнивают между собой (combinations of independent variables to be tested). Например: Treatment A = схема оплаты «процент», Treatment B = схема «бонус при x».

План эксперимента (experimental design)

Статистический эксперимент (statistical experiment) обычно включает шаги:

1. Выбрать экспериментальные единицы (choose experimental units)
2. Разделить их на группы, которые получат разные воздействия (divide into groups for different treatments)
3. Применить воздействия (apply treatments)
4. Сравнить результаты и сделать выводы (compare results and draw conclusions)

План эксперимента (experimental design) — это именно план того, *как* мы назначаем treatments экспериментальным единицам (то есть шаг 2).

Смешивание факторов (confounding) и зачем нужна рандомизация (randomization)

Смешанные/конфундированные переменные (confounded variables / confounding factors) — это ситуация, когда мы не можем понять, что именно вызвало эффект, потому что факторы «перепутались».

Пример из лекции: тестируем два лекарства (testing two medicines)

- Группа 1: молодые пациенты получают лекарство A (young + Medicine A)
- Группа 2: пожилые пациенты получают лекарство B (elder + Medicine B)

Если результат у групп разный — мы не можем сказать, почему: это лекарство лучше или возраст влияет? Здесь лечение (treatment) и возраст (age) **конфундированы**. Возраст — **confounding variable**.

Рандомизация (randomization) — стратегия, которая уменьшает влияние confounding variables: мы распределяем участников случайно, чтобы группы были максимально похожи.

Общее правило (general rule): группы для разных treatments должны быть максимально одинаковыми (maximally similar) и отличаться *в идеале только* назначенным treatment.

Три базовых дизайна рандомизированных экспериментов (randomized designs)

1) Полностью рандомизированный дизайн (completely randomized design)

Участников распределяют по treatments случайно.

Пример из лекции: 600 испытуемых (600 subjects), 2 лечения

- Treatment A: 300 subjects
- Treatment B: 300 subjects

Замечания:

- часто группы делают примерно равными по размеру (equal sizes), но это не строго обязательно;
- treatments может быть больше двух (more than 2 groups).

2) Рандомизированный блочный дизайн (randomized block design)

Идея: сначала разбиваем экспериментальные единицы на блоки (blocks) по важному признаку, который может быть confounder, а потом внутри каждого блока делаем случайное назначение treatments.

Шаги:
(a) Разделить units на подгруппы — блоки (divide into blocks)

(b) Внутри каждого блока случайно назначить treatment (randomly assign within each block)

Пример (таблица):

- Male: Treatment A — 100, Treatment B — 100
- Female: Treatment A — 100, Treatment B — 100
- Child: Treatment A — 100, Treatment B — 100

Идея “в идеале”: каждую комбинацию потенциально смешивающих факторов (each combination of possibly confounding variables) — в отдельный блок. Но это часто сложно, если факторов много.

3) Парный/сопоставленный дизайн (matched design)

Это частный случай блокового дизайна, где каждый блок содержит ровно 2 единицы (по одной на каждое лечение) — либо nnn единиц, если treatments nnn.

Смысл: элементы внутри пары подбираются максимально похожими (most similar). Часто это:

- либо два очень похожих человека (по возрасту, полу, уровню и т.д.),
- либо **один и тот же человек в разные моменты времени** (same unit at different time moments), например “до/после”.

Пример из лекции:

Пары 1…300, и в каждой паре:

- один получает Treatment A
- другой получает Treatment B

Про placebo и blinding

В этой конкретной презентации темы 2 явных слайдов про **placebo (плацебо)** и **blinding (ослепление)** я не вижу. Если хочешь — я добавлю их как стандартные элементы дизайна медицинских экспериментов (single-blind / double-blind, placebo effect) **следующим сообщением**, но уже как “расширение”, а не буквальный перевод слайдов.

Смещения в выборочных исследованиях (bias in sample studies)

Даже если исследование выглядит “большим” и собрано много данных, результаты могут быть неверными из-за **смещения (bias)** — систематической ошибки, которая уводит оценку в одну сторону. В отличие от **ошибки выборки (sampling error)**, смещение не “лечится” просто увеличением nnn: можно получить очень точную, но неправильную оценку.

1) Смещение охвата (undercoverage bias) / ошибка рамки выборки (sampling frame)

Undercoverage возникает, когда список, из которого мы выбираем людей (sampling frame), **не покрывает** часть генеральной совокупности (population).

Пример (пример из лекционной логики):

- Опрос “по стационарным телефонам” пропускает людей без стационарного телефона.
- Онлайн-опрос пропускает тех, кто не пользуется интернетом.
- Опрос “в центре города” пропускает жителей окраин.

Итог: некоторые группы систематически недопредставлены → оценка смещена.

2) Смещение самоотбора (voluntary response bias)

Voluntary response sample — когда люди сами решают участвовать (обычно по объявлению/ссылке). Часто отвечают те, кому тема особенно важна или кто эмоционально вовлечён.

Типичный пример:
опрос на сайте/в соцсети про качество сервиса — чаще отвечают очень недовольные или очень довольные, а “нормальные” молчат. Средняя оценка становится не репрезентативной.

3) Смещение из-за неответов (nonresponse bias)

Nonresponse — мы отобрали людей правильно, но часть не ответила, и это связано с темой исследования.

Пример:

- люди с высоким доходом чаще отказываются говорить про доход → средний доход по ответам занижен;

- сотрудники, которые боятся начальства, не отвечают на опрос удовлетворённости → удовлетворённость по ответам завышена.

4) Смещение ответа (response bias)

Response bias — человек отвечает не так, как есть на самом деле, из-за:

- социальной желательности (social desirability),
- стресса/страха,
- плохой памяти,
- желания “выглядеть лучше”.

Пример:
вопросы про алкоголь, курение, доход, нарушения правил — люди часто занижают “плохое” и завышают “хорошее”.

5) Эффект формулировки (wording effect) и наводящие вопросы (leading questions)

Даже нейтральный по смыслу вопрос может давать разные ответы из-за формулировки.

Пример (типовой):

- “Поддерживаете ли вы запрет X ради безопасности?” vs
- “Поддерживаете ли вы запрет X, ограничивающий свободы?”

Смысл рядом, но эмоциональная окраска разная → ответы смещаются.

6) Удобная выборка (convenience sampling)

Convenience sample — берём тех, кого легко взять: “кто рядом”, “кто согласился”, “моя группа студентов”.

Пример:
оценивать “мнение жителей города” по студентам одного вуза — быстро, но обычно не репрезентативно.

Что обычно делают, чтобы уменьшить bias (как практическое правило)

- улучшать рамку выборки (better sampling frame);

- использовать рандомизацию/вероятностный отбор (probability sampling);
- повышать отклик: напоминания, разные каналы, короткая анкета (increase response rate);
- пилотировать вопросы (pilot test) и убирать наводящие формулировки;
- контролировать репрезентативность по ключевым признакам (post-stratification / weighting).