Лекция. Доверительные интервалы через пивотальную статистику

1. Зачем нужна пивотальная статистика

В первой части мы уже увидели, что доверительный интервал строится не сам по себе, а через некоторое вероятностное утверждение.

Например, если удаётся получить соотношение вида

$$P(a \le T(X,\theta) \le b) = 1-\alpha,$$

то, решая это неравенство относительно θ, мы получаем доверительный интервал.

Но здесь возникает главный вопрос:

какую именно статистику $T(X,\theta)$ нужно брать?

Ответ: нужно искать такую статистику, распределение которой **известно** и при этом **не зависит от неизвестного параметра**.

Именно такая статистика и называется **пивотальной**.

Пивотальная статистика — это статистика, зависящая от выборки и параметра, распределение которой не зависит от неизвестного параметра. Она не обязана быть оценкой. Её смысл в том, что она превращает задачу с неизвестным параметром в задачу с известным распределением, а потому служит основным инструментом для построения доверительных интервалов и статистических критериев.

Простой пример

Пусть

$$X_1, \dots, X_n \sim N(\mu, \sigma^2),$$

и σ известно.

Тогда

$$\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Рассмотрим величину

$$T = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}.$$

Она зависит от μ, но её распределение:

$$T \sim N(0,1),$$

а оно уже **не зависит от μ**.

Значит, это и есть пивотальная статистика.

2. Определение пивотальной статистики

Определение

Пусть

$$X_1, \dots, X_n \sim f(x; \theta),$$

где θ — неизвестный параметр.

Статистика

$$T = T(X_1, \dots, X_n, \theta)$$

называется **пивотальной статистикой** или **пивотом**, если её распределение **не зависит от неизвестного параметра θ**.

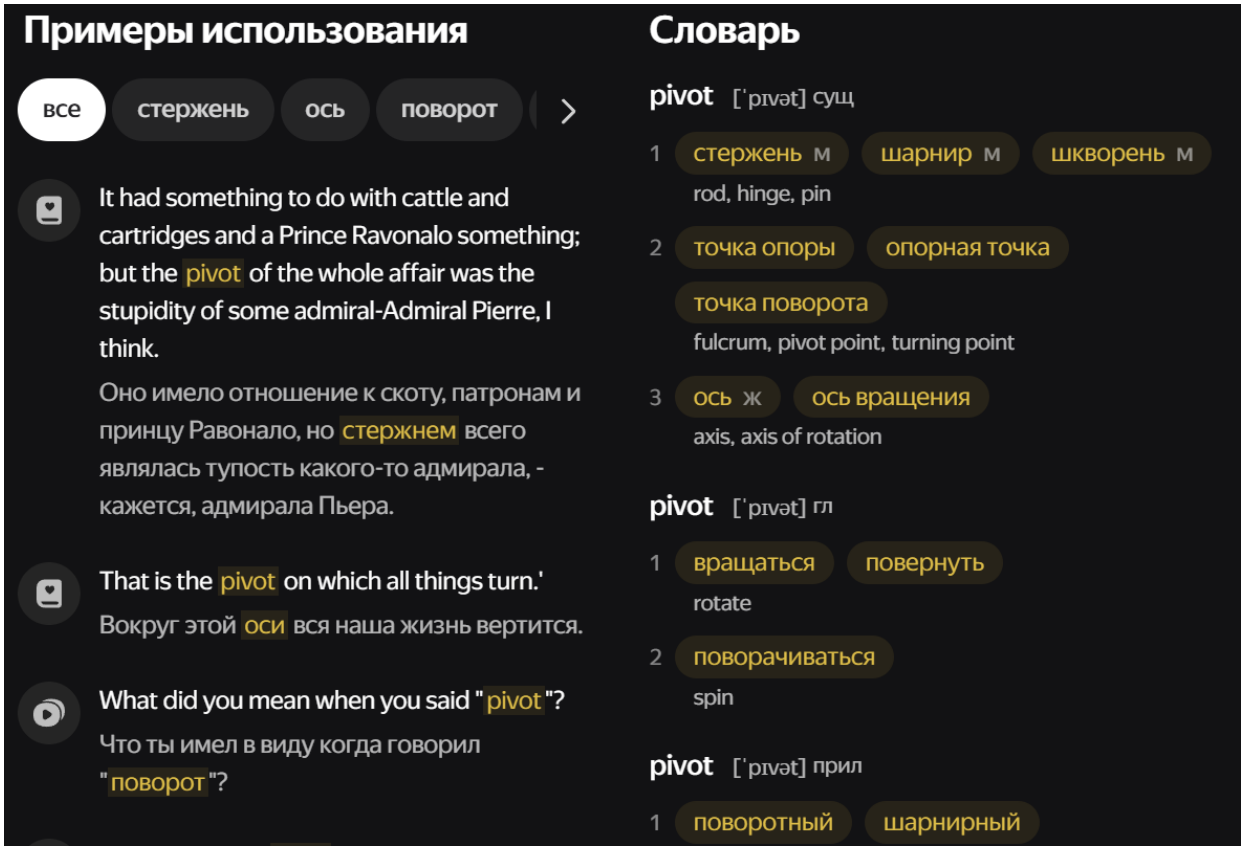

Пояснение к определению

Это означает, что в выражении T сам параметр θ может присутствовать, но после того как мы найдём распределение этой величины, окажется, что оно уже не содержит θ.

То есть пивот — это такая комбинация:

- данных выборки,
- неизвестного параметра,

которая имеет **полностью известное распределение**.

Именно поэтому пивот так удобен: с ним можно работать как с обычной случайной величиной с известными квантилями.

3. Почему пивотальная статистика так важна

Основной тезис

Пивотальная статистика — это **основной инструмент построения точных доверительных интервалов**.

Причина очень простая.

Если известно распределение $T(X, \theta)$, то можно написать вероятностное утверждение вида

$$P(c_1 \leq T(X, \theta) \leq c_2) = 1 - \alpha,$$

где c_1 и c_2 — квантили этого известного распределения.

После этого остаётся только преобразовать неравенство и выразить из него θ.

Идея в одной фразе

Доверительный интервал строится путём обращения вероятностного утверждения для пивотальной статистики.

4. Схема построения доверительного интервала через пивот

Теперь запишем общий алгоритм.

Общая схема

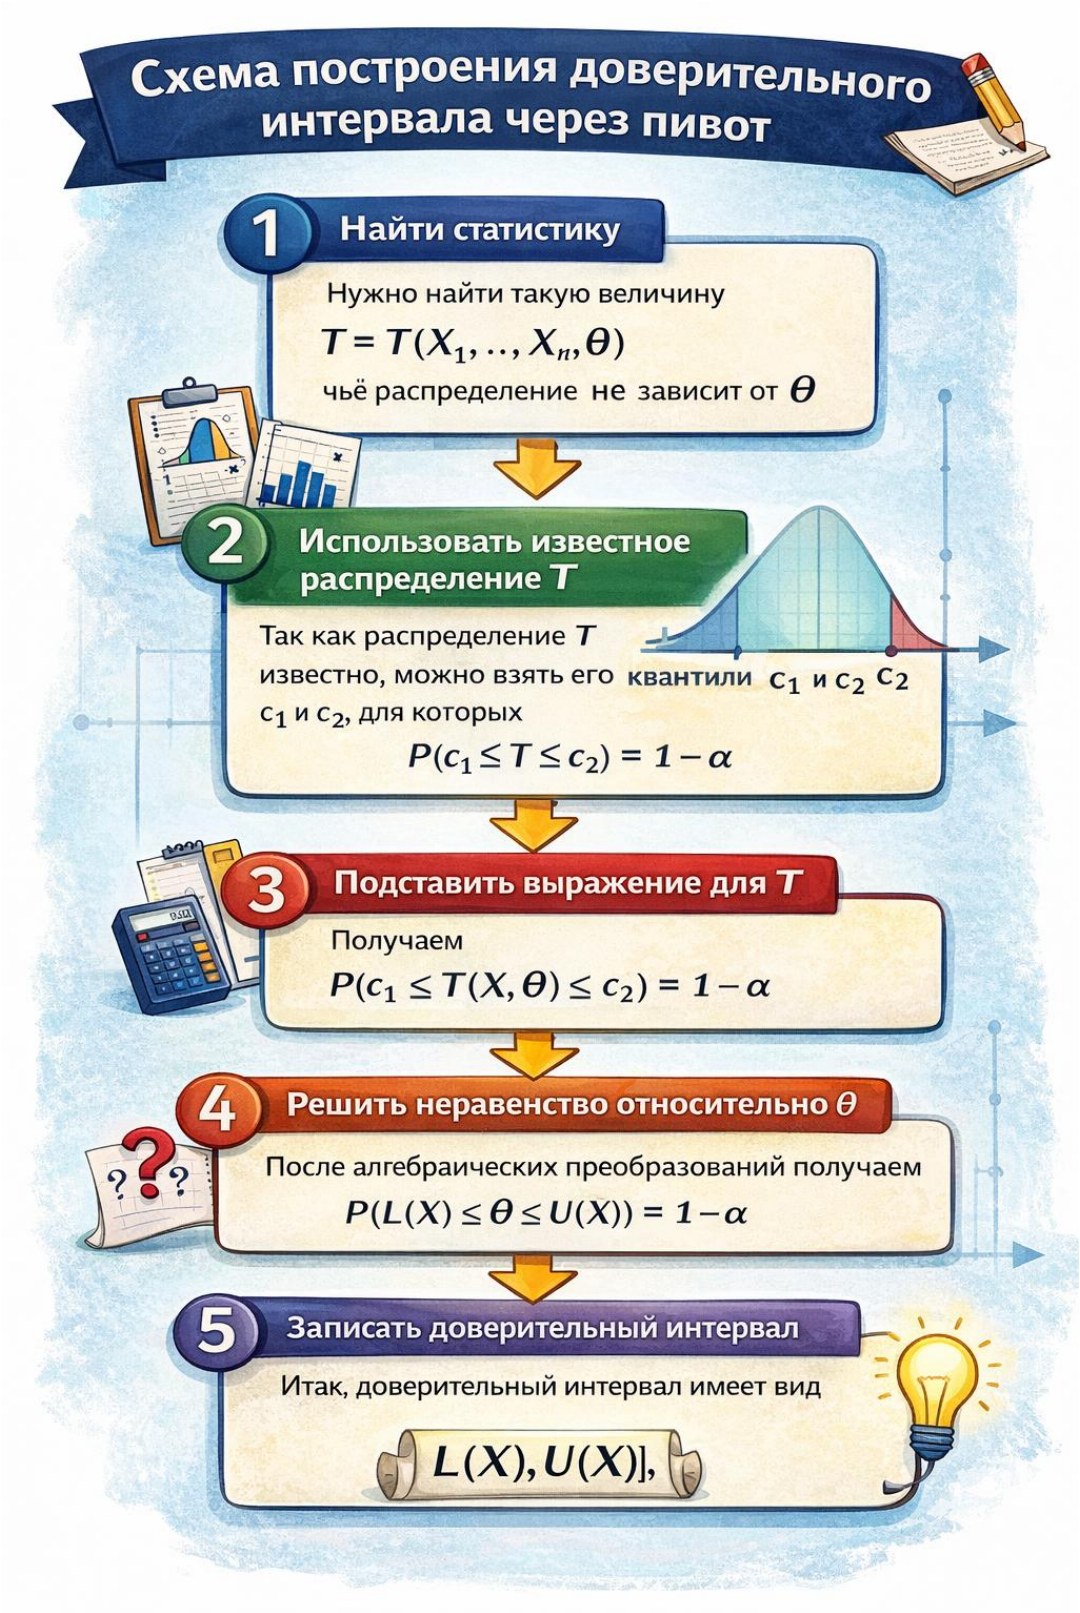

5. Как распознать пивотальную статистику

Это очень важный методический момент. Студенты часто понимают готовый пример, но не понимают, **как догадаться**, какую статистику брать.

Здесь полезно сформулировать набор ориентиров.

Признак 1. Нужно убрать неизвестный параметр из распределения

Если статистика зависит от θ, это ещё не проблема. Проблема только тогда, когда и её **распределение** зависит от θ.

Поэтому цель — подобрать преобразование, после которого распределение станет стандартным:

- нормальным,
- распределением Стьюдента,
- хи-квадрат,
- бета,
- гамма,
- или вообще любым другим известным распределением.

Признак 2. Пивот часто возникает через стандартизацию

Очень часто пивотальная статистика — это результат стандартизации.

Например, если

$$\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

то

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1).$$

Здесь

$$T = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \text{ — пивот.}$$

Признак 3. Пивот часто строится из достаточной статистики

Во многих задачах сначала находят достаточную статистику:

- сумму,
- максимум,
- минимум,
- выборочное среднее,
- выборочную дисперсию,

а потом смотрят, можно ли из неё сделать пивот.

Признак 4. Пивот особенно легко искать в классических семействах

Наиболее типичные случаи:

1. Нормальное распределение
2. Экспоненциальное распределение
3. Равномерное распределение
4. Гамма-распределение
5. Пуассоновское распределение
6. Биномиальное распределение

Именно там обычно есть точные доверительные интервалы.

7. Основные типы пивотальных статистик

Теперь полезно классифицировать пивоты по виду.

Тип 1. Пивот вида «оценка минус параметр»

Например,

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1).$$

Здесь пивот строится как

$$\frac{\text{оценка} - \text{параметр}}{\text{масштаб (SE)}}.$$

Это типично для нормальных и асимптотических задач.

Тип 2. Пивот вида «отношение статистики к параметру»

Например, для дисперсии:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Или для равномерного распределения:

$$\frac{X_{(n)}}{\theta}.$$

Это удобно, когда параметр играет роль масштаба.

Тип 3. Пивот вида «параметр умножить на статистику»

Например, для экспоненциального распределения:

$$2\lambda \sum_{i=1}^{n} X_i \sim \chi^2_{2n}.$$

Это особенно часто бывает в гамма- и экспоненциальных моделях.

Тип 4. Пивот через разность между порядковой статистикой и параметром

Например, если

$$X_i \sim U(\theta, \theta + 1),$$

то разумно рассматривать

$$X_{(1)} - \theta \quad \text{или} \quad X_{(n)} - \theta.$$

Это типичный случай для параметров сдвига.

Гамма-распределение

1. Что такое гамма-распределение

Гамма-распределение — это семейство **непрерывных распределений**, заданных на положительной полуоси. То есть случайная величина X может принимать только положительные значения:

$$x \in (0, \infty).$$

Обычно его используют для моделирования **положительных величин**: времени ожидания, длительности процессов, суммарного времени до нескольких событий и других неотрицательных величин с правой асимметрией. Если параметр формы принимает целое значение, то соответствующий частный случай называется **распределением Эрланга**.

2. Плотность гамма-распределения

Говорят, что случайная величина X имеет гамма-распределение с параметрами $k > 0$ и $\theta > 0$, если её плотность задаётся формулой

$$f_X(x) = \begin{cases} \dfrac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-x/\theta}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Здесь:

- k — **параметр формы**,
- θ — **параметр масштаба**,
- $\Gamma(k)$ — **гамма-функция Эйлера**.

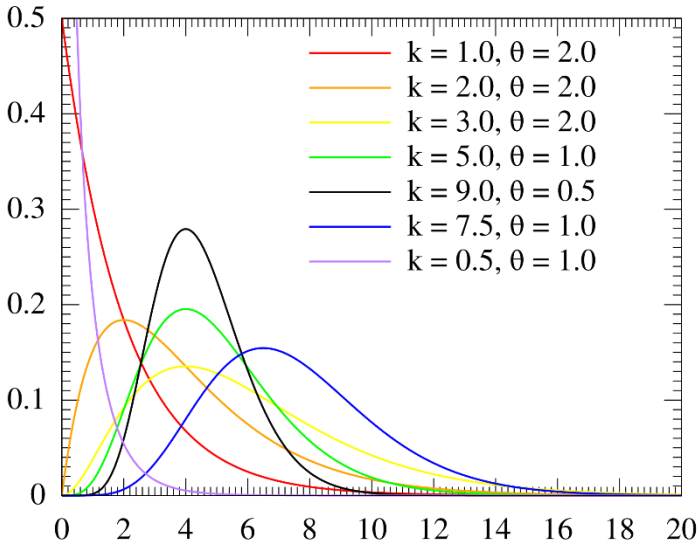

3. Что делают параметры k и θ

Параметр формы k

Параметр k отвечает за форму распределения.

- При малых k распределение обычно сильнее скошено вправо.
- При больших k оно становится более сглаженным.

- Если k — натуральное число, гамма-распределение можно интерпретировать как распределение суммы нескольких независимых экспоненциальных случайных величин. Именно поэтому при целых k возникает распределение Эрланга.

Параметр масштаба θ

Параметр θ отвечает за “растяжение” распределения по оси x. Чем больше θ, тем в среднем больше значения случайной величины и тем больше разброс. Это сразу видно по формулам для математического ожидания и дисперсии.

Идея графика в том, что гамма-распределение — очень гибкое: оно может выглядеть и почти как экспоненциальное распределение, и как более симметричное распределение для положительных величин.

4. Числовые характеристики

Для случайной величины

$$X \sim \Gamma(k, \theta)$$

имеем:

Математическое ожидание

$$E[X] = k\theta.$$

Дисперсия

$$Var[X] = k\theta^2.$$

5. Вставка: что такое гамма-функция Эйлера

В формуле плотности есть запись $\Gamma(k)$.

Её не нужно воспринимать как что-то “чужое” или случайное. По смыслу это просто специальная функция, которая **обобщает факториал**.

Она определяется так:

$$\Gamma(s) = \int_0^\infty x^{s-1}\, e^{-x}\, dx, \qquad s > 0.$$

Главный факт, который полезно помнить:

$$\Gamma(n) = (n-1)!, \quad n \in N.$$

То есть гамма-функция — это почти факториал, только со сдвигом на единицу. Например,

$$\Gamma(1) = 1, \qquad \Gamma(2) = 1! = 1, \qquad \Gamma(3) = 2! = 2, \qquad \Gamma(4) = 3! = 6.$$

Почему так получается? Потому что для гамма-функции верно рекуррентное свойство

$$\Gamma(s+1) = s\,\Gamma(s).$$

Если подставлять натуральные значения, получаем ту же самую схему, что и у факториала. Поэтому Γ(k) в формуле плотности — это естественный аналог факториала для непрерывного параметра.

Зачем $\Gamma(k)$ стоит в плотности

Без множителя

$$\frac{1}{\Gamma(k)\theta^k}$$

функция

$$x^{k-1}e^{-x/\theta}$$

была бы просто положительной функцией, но ещё не плотностью. Гамма-функция здесь нужна как **нормирующий множитель**, чтобы выполнялось условие

$$\int_0^\infty f_X(x)\ dx = 1.$$

То есть очень простыми словами:

Γ(k) нужна для того, чтобы площадь под графиком плотности была равна единице.

6. Основные свойства гамма-распределения

Вот свойства, которые особенно важны для статистики.

Свойство 1. Сумма независимых гамма-величин

Если

$$X_1, \dots, X_n$$

независимы и

$$X_i \sim \Gamma(k_i, \theta),$$

то

$$\sum_{i=1}^{n} X_i \sim \Gamma\left(\sum_{i=1}^{n} k_i\,, \theta\right).$$

Это одно из самых полезных свойств гамма-распределения. Именно оно делает его удобным в задачах про суммы времен ожидания.

Свойство 2. Масштабирование

Если

$$X \sim \Gamma(k, \theta), \qquad a > 0,$$

то

$$aX \sim \Gamma(k, a\theta).$$

То есть умножение случайной величины на положительную константу меняет масштаб, но не меняет параметр формы.

7. Связь с экспоненциальным распределением

Для нас это особенно важно, потому что дальше это напрямую используется при построении доверительного интервала для параметра λ в экспоненциальном распределении.

Экспоненциальное распределение — это частный случай гамма-распределения:

$$\Gamma(1,1/\lambda) \equiv Exp(\lambda).$$

Поэтому если

$$X_1, \dots, X_n \sim Exp(\lambda),$$

то каждое X_i можно рассматривать как гамма-распределённую величину с параметрами

$$k = 1, \qquad \theta = \frac{1}{\lambda}.$$

Тогда сумма

$$S = \sum_{i=1}^{n} X_i$$

имеет распределение

$$S \sim \Gamma\left(n, \frac{1}{\lambda}\right).$$

Именно отсюда потом рождается пивотальная статистика и появляется связь с распределением χ^2.

Можно ли сказать, что если какие-то параметры изменить, то она будет стремиться к нормальному распределению?

Да, **можно**.

Корректнее сказать так:

При увеличении параметра формы гамма-распределение становится менее скошенным и по форме всё больше напоминает нормальное распределение.

Если записать

$$X \sim \Gamma(k, \theta),$$

то при больших k:

- распределение становится более симметричным,
- пик смещается вправо,
- относительная асимметрия уменьшается,
- после центрирования и нормировки оно приближается к нормальному распределению.

Более строго:

$$E[X] = k\theta, \qquad D[X] = k\theta^2.$$

Тогда при $k \to \infty$

$$\frac{X - k\theta}{\theta\sqrt{k}} \Longrightarrow N(0,1).$$

То есть не само гамма-распределение “становится нормальным” буквально на той же шкале, а **нормированная гамма-случайная величина** сходится по распределению к стандартному нормальному закону.

Доверительный интервал для параметра λ в экспоненциальном распределении

1. Постановка задачи

Пусть

$$X_1, X_2, \dots, X_n$$

— независимая выборка из экспоненциального распределения с параметром $\lambda > 0$, то есть с плотностью

$$f(x;\lambda) = \lambda e^{-\lambda x}, \qquad x > 0.$$

Требуется построить доверительный интервал уровня доверия $1 - \alpha$ для параметра λ.

2. Общая идея

Чтобы построить доверительный интервал, нам нужно:

1. выбрать статистику, связанную с λ;
2. найти её распределение;
3. построить пивотальную статистику;
4. выписать вероятностное неравенство уровня 1−α;
5. решить его относительно λ.

Для экспоненциального распределения естественной статистикой является сумма

$$S = \sum_{i=1}^{n} X_i.$$

Это хороший выбор, потому что сумма независимых экспоненциальных величин имеет гамма-распределение.

3. Доказательство.

Так как

$$S = \sum_{i=1}^{n} X_i \sim \Gamma\left(n, \frac{1}{\lambda}\right),$$

то

$$2\lambda S \sim \chi^2_{2n}.$$

Следовательно,

$$P\left(\chi^2_{2n;\alpha/2} \le 2\lambda S \le \chi^2_{2n;1-\alpha/2}\right) = 1 - \alpha.$$

После деления на 2S2 получаем

$$P\left(\frac{\chi^2_{2n;\alpha/2}}{2S} \le \lambda \le \frac{\chi^2_{2n;1-\alpha/2}}{2S}\right) = 1 - \alpha.$$

Теорема доказана.

Чуть понятнее:

$$\left[\frac{\chi^2_{2n;\alpha/2}}{2\sum_{i=1}^n X_i}, \frac{\chi^2_{2n;1-\alpha/2}}{2\sum_{i=1}^n X_i}\right].$$

Можно записать так:

$$P\left(\frac{\chi^2_{2n;\alpha/2}}{2n\overline{X}} \le \lambda \le \frac{\chi^2_{2n;1-\alpha/2}}{2n\overline{X}}\right) = 1 - \alpha.$$

Интервал для среднего экспоненциального распределения

Если вместо параметра λ нас интересует среднее

$$\theta = \frac{1}{\lambda},,$$

то из уже полученного интервала можно получить интервал для θ.

Если

$$a \le \lambda \le b,$$

то

$$\frac{1}{b} \le \frac{1}{\lambda} \le \frac{1}{a}.$$

Поэтому доверительный интервал для

$$\theta = \frac{1}{\lambda}$$

имеет вид

$$P\left(\frac{2\sum_{i=1}^n X_i}{\chi^2_{2n;1-\alpha/2}} \le \theta \le \frac{2\sum_{i=1}^n X_i}{\chi^2_{2n;\alpha/2}}\right) = 1 - \alpha.$$

Или

$$P\left(\frac{2\overline{X}}{\frac{1}{n}\cdot\chi^2_{2n;1-\alpha/2}} \le \theta \le \frac{2\overline{X}}{\frac{1}{n}\cdot\chi^2_{2n;\alpha/2}}\right) = 1-\alpha.$$

Доверительный интервал для параметра θ в распределении U(0,θ)

1. Постановка задачи

Пусть

$$X_1, \dots, X_n$$

— независимая выборка из равномерного распределения на отрезке [0,θ], где θ>0 неизвестно.

Плотность имеет вид

$$f(x;\theta) = \begin{cases} \frac{1}{\theta}, & 0 \le x \le \theta, \\ 0, & \text{иначе.} \end{cases}$$

Требуется построить доверительный интервал уровня 1−α для параметра θ.

2. Какая статистика здесь естественна

Для этой модели параметр θ — это **правая граница распределения**.

Значит, наиболее информативная статистика здесь — это максимум выборки:

$$X_{(n)} = \max(X_1, \dots, X_n).$$

Почему именно максимум?

Потому что все наблюдения обязаны лежать в пределах от 0 до θ, и именно максимальное наблюдение ближе всего подходит к неизвестной верхней границе θ.

3. Найдём распределение максимума

Сначала найдём функцию распределения $X_{(n)}$.

Для $0 \le x \le \theta$:

$$P\left(X_{(n)} \le x\right) = P(X_1 \le x, \dots, X_n \le x).$$

Так как величины независимы, имеем

$$P\left(X_{(n)} \leq x\right) = \prod_{i=1}^{n} P(X_i \leq x).$$

Но для равномерного распределения $U(0, \theta)$

$$P(X_i \leq x) = \frac{x}{\theta}, \qquad 0 \leq x \leq \theta.$$

Следовательно,

$$P\left(X_{(n)} \leq x\right) = \left(\frac{x}{\theta}\right)^n, \qquad 0 \leq x \leq \theta.$$

Значит, функция распределения максимума:

$$F_{X_{(n)}}(x) = \begin{cases} 0, & x < 0, \\ \left(\frac{x}{\theta}\right)^n, & 0 \leq x \leq \theta, \\ 1, & x \geq \theta. \end{cases}$$

Значит,

$$T = \frac{X_{(n)}}{\theta}$$

— это пивотальная статистика.

Тогда

$$P\left(a \leq \frac{X_{(n)}}{\theta} \leq b\right) = 1 - \alpha.$$

Теперь решаем это неравенство относительно θ.

Итак,

$$P\left(\frac{X_{(n)}}{b} \leq \theta \leq \frac{X_{(n)}}{a}\right) = 1 - \alpha.$$

Доверительный интервал для параметра λ в распределении Пуассона

1. Постановка задачи

Пусть

$$X_1, \dots, X_n$$

— независимая выборка из распределения Пуассона с параметром λ>0:

$$X_i \sim Pois(\lambda).$$

Тогда

$$P(X_i = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \qquad k = 0,1,2,\dots$$

Требуется построить доверительный интервал уровня доверия 1−α для параметра λ.

2. Естественная статистика

Для распределения Пуассона естественная статистика — это сумма выборки:

$$S = \sum_{i=1}^{n} X_i = s.$$

Почему именно она?

Потому что сумма независимых пуассоновских случайных величин снова имеет распределение Пуассона, а именно:

$$S \sim Pois(n\lambda).$$

Это ключевой факт.

То точный доверительный интервал уровня 1−α для параметра λ имеет вид

$$\boxed{\left[\frac{1}{2n}\chi^2_{2s;\alpha/2}, \frac{1}{2n}\chi^2_{2s+2;1-\alpha/2}\right]}$$

где:

- $2\chi^2_{df;\gamma}$ — квантиль уровня γ распределения χ^2 с df степенями свободы;
- $s = \sum_{i=1}^{n} X_i$.

Если n достаточно велико (n > 30), то можно использовать:

Асимптотический доверительный интервал:

$$\boxed{\left[\overline{X} - z_{1-\alpha/2}\sqrt{\frac{\overline{X}}{n}},\ \overline{X} + z_{1-\alpha/2}\sqrt{\frac{\overline{X}}{n}}\right]}$$