Yandex Cloud

Облачные технологии в работе с большими данными. День 12

Баташов Руслан

Хранение и анализ данных

1. Объектное хранилище. Создание бакетов и загрузка объектов.
2. БД. Создание кластера БД и подключение к ней. PostgreSQL/MySQL/MongoDB/ClickHouse
3. Hadoop. Создание и подключение к кластеру, работа с Hive.
4. Создание датасетов, чартов и дашбордов в DataLens.
5. Построение корпоративной аналитической платформы

Введение

Интернет-магазин. Покупатели размещают в нем заказы, а отгрузка происходит из ближайшей выбранной точки. Чтобы работа шла бесперебойно, товарные запасы должны поддерживаться на оптимальном уровне. «Оптимальный» означает, что запасов хватает, чтобы отгружать все текущие заказы, но при этом товары не занимают много складского пространства. Проще говоря: покупатели получают товар вовремя, а склады не переполнены.

Задача: нужно создать дашборды с аналитическими отчетами, которые будут обновляться в реальном времени. На их основе руководители смогут принимать управленческие решения: уменьшать или увеличивать запасы в конкретной точке отгрузки.

Нюансы: вся инфраструктура магазина развернута в «облаке». При этом складские запасы и информация о заказах хранятся в разных местах:

- информация об остатках хранится в корпоративном хранилище данных, построенном, например, на базе Microsoft SQL Server или Oracle. Однако возможности сервера ограничены, и хранятся только данные за последний квартал;
- онлайн-заказы поступают через веб-сайт или мобильное приложение и хранятся в базе данных MySQL или PostgreSQL — одном из двух наиболее популярных решений. Опять же из-за технических ограничений хранятся только данные за прошедший месяц.

Модули

1. Научимся передавать данные в промежуточные хранилища. В первой части будем загружать данные из MySQL с помощью инструмента Yandex Data Transfer. Получим данные о торговых остатках нашего интернет-магазина;
2. Организуем «гибридную» обработку и хранение данных в аналитической базе данных ClickHouse.
3. Свяжем ClickHouse с инструментом для построения аналитических витрин — Yandex DataLens.
4. Построим сводные аналитические панели — дашборд. На нем создадим «тепловую карту» заказов в регионе.

Схема

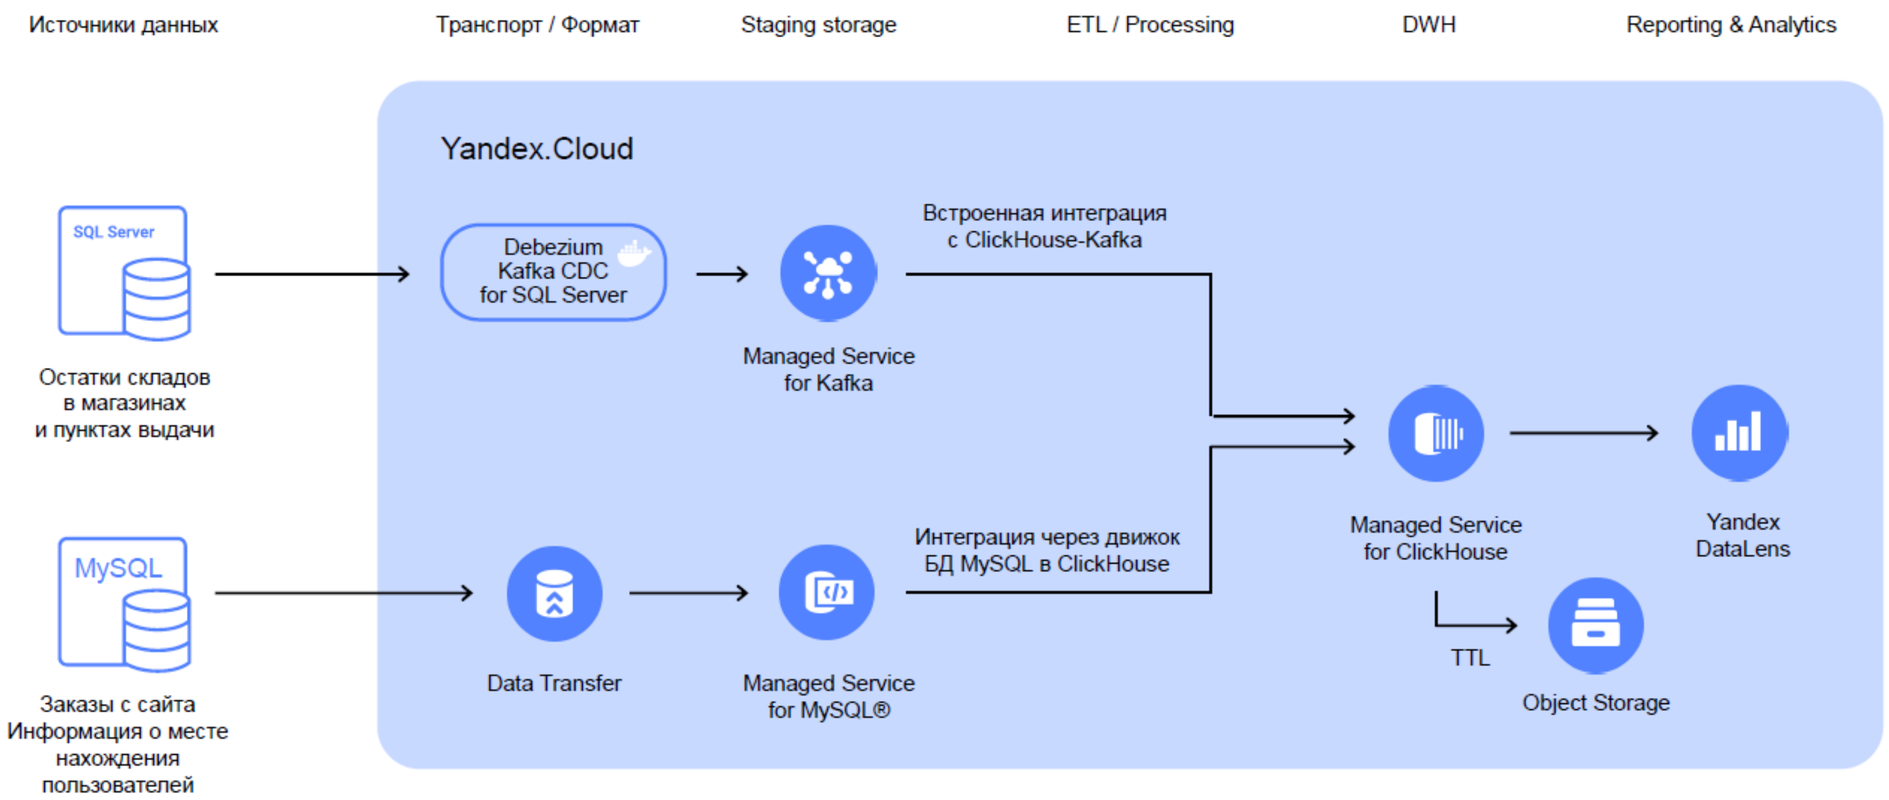
Источники данных
Транспорт / Формат
Staging storage
ETL / Processing
DWH
Reporting & Analytics
Yandex.Cloud
SQL Server
Остатки складов
в магазинах
и пунктах выдачи
Debezium
Kafka CDC
for SQL Server
Managed Service
for Kafka
Встроенная интеграция
с ClickHouse-Kafka
MySQL
Заказы с сайта
Информация о месте
нахождения
пользователей
Data Transfer
Managed Service
for MySQL®
Интеграция через движок
БД MySQL в ClickHouse
Managed Service
for ClickHouse
Yandex
DataLens
TTL
Object Storage

Синхронизация данных из MySQL

1. Создадим виртуальный диск из образа с предварительно настроенной платформой интернет-магазина magento. Для этого откройте любую командную строку и введите команду:

```
yc compute disk create \
--zone ru-central1-a \
--name web-store-lab-dataplatform \
--source-image-id fd86cb7ugap89m9ja920 \
--folder-id <your-yc-folder-id>
```

2. Теперь создадим виртуальную машину. Введите в консоли команду:

```
yc compute instance create \
--name magento \
--zone ru-central1-a \
--network-interface subnet-name=default-ru-central1-a,nat-ip-version=ipv4 \
--hostname ya-sample-store \
--use-boot-disk disk-name=web-store-lab-dataplatform \
--folder-id <your-yc-folder-id> \
--ssh-key ~/.ssh/id_rsa.pub
```

3. Подключитесь к ВМ по SSH

```
ssh yc-user@<ip-address-vm>
```

Схему данных интернет-магазина можно посмотреть при помощи DBeaver. При подключении нужно указывать:

- **Server Host:** <публичный_IP-адрес_виртуальной_машины>
- **Port:** 3306
- **Имя базы данных:** *ya_sample_store*
- **Имя пользователя:** *magento-svc*
- **Пароль:** *m@gent0*

4. Для реплицирования таблиц с информацией о заказах интернет-магазина создадим кластер Managed Service for MySQL:

- Выберите сервис Managed Service for MySQL и нажмите **Создать кластер.**
- Задайте имя кластера *ya-sample-cloud-mysql.*
- **Имя базы данных:** *magento-cloud*
- **Имя пользователя:** *yc-user*
- **Пароль:** *12345678*
- *Остальные параметры выберите по умолчанию*
- Нажмите кнопку **Создать кластер**

Синхронизация данных из MySQL

Чтобы синхронизировать информацию о заказах из БД MySQL интернет-сайта с промежуточным хранилищем данных, которое находится в облаке, настроим Data Transfer.

5. Выберите сервис Data Transfer и нажмите **Создать эндпойнт**.
6. Определите параметры источника данных — виртуальной машины интернет-магазина с запущенным на ней экземпляром MySQL:
   - **Имя:** *magento-source*
   - Выберите из списка **тип БД:** MySQL
   - **IP хоста:** <публичный_IP-адрес_виртуальной_машины>
   - **Имя базы данных:** *ya_sample_store*
   - **Имя пользователя:** *magento-svc*
   - **Пароль:** *m@gent0*
   - В **белом списке** укажите префиксы таблиц, которые подлежат репликации, например, *sales_**
   - Нажмите кнопку **Создать**

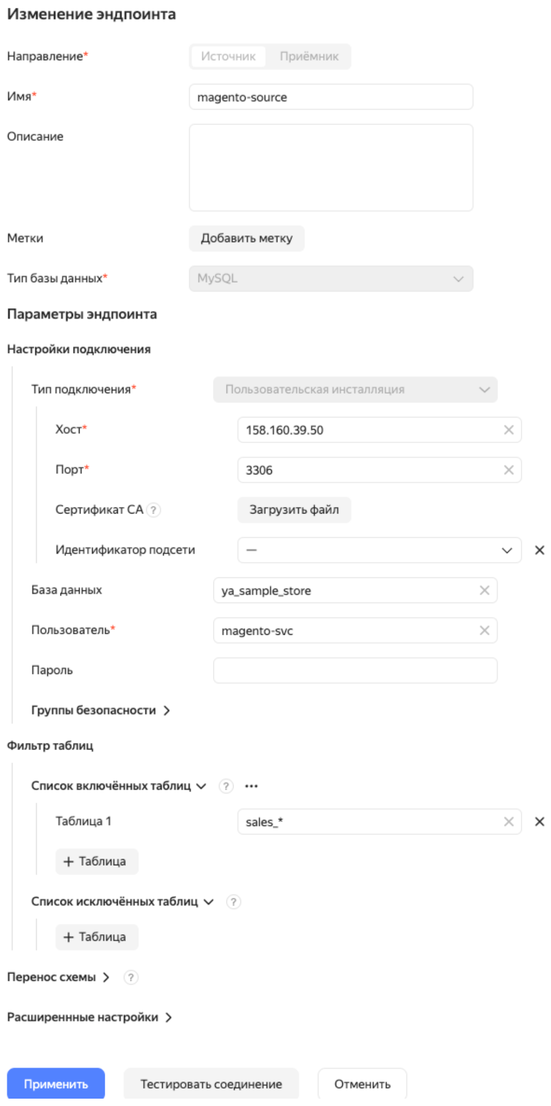

7. Определите параметры приемника данных — управляемой базы данных Managed Service for MySQL, которая находится в облаке:
   - **Имя:** *magento-report-dest*
   - **База данных:** Managed Service for MySQL
   - Выберите из списка **идентификатор кластера:** *ya-sample-cloud-mysql*
   - **Имя базы данных:** *magento-cloud*
   - **Имя пользователя** репликации: *yc-user*
   - **Пароль:** *12345678*
   - В строке **Отключение проверки констрейнтов** поставьте галочку. Если порядок передачи данных будет нарушен, сообщения об ошибках выдаваться не будут.
   - Нажмите кнопку **Создать**.

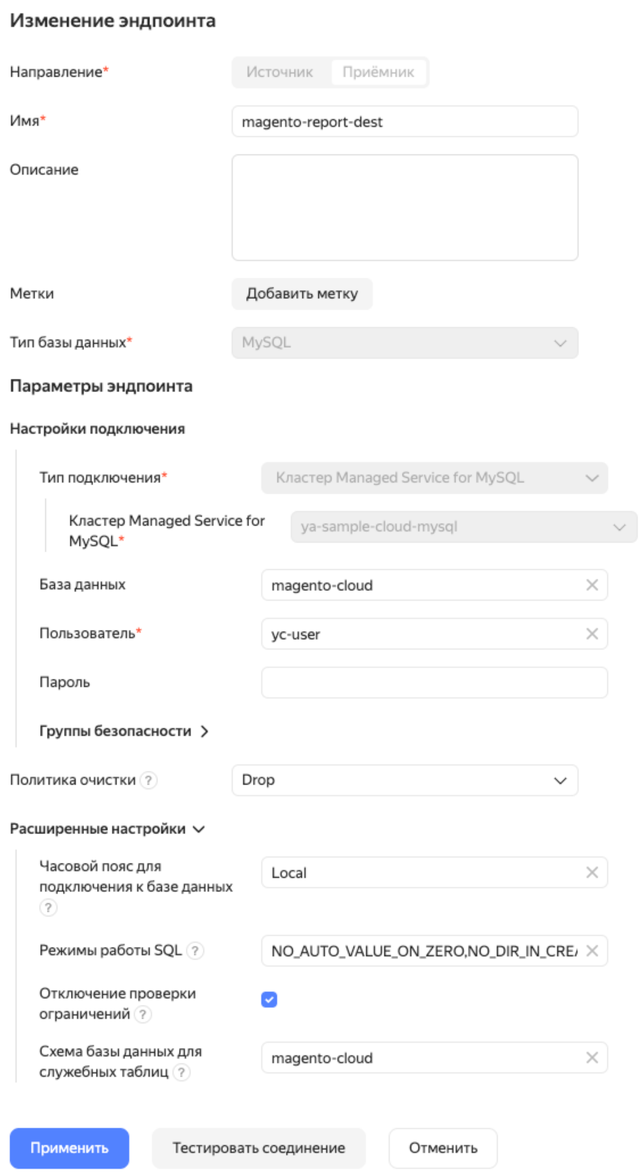

8. Выберите в меню раздел Трансферы и нажмите кнопку **Создать трансфер**. Далее определим параметры трансфера:
   - **Имя:** *sales-order-sync*
   - В блоке **Источник** выберите эндпойнт *magento-source.*
   - В блоке **Приемник** выберите эндпойнт *magento-report-dest.*
   - В блоке **Тип трансфера** выберите *Копировать и реплицировать.*
   - Нажмите кнопку **Создать.**

8. Нажмите на три точки в строке с описанием трансфера и выберите **Активировать**.
   Будет выполнена первоначальная синхронизация схем данных и другой информации, а в дальнейшем данные будут автоматически синхронизироваться при появлении изменений в базе данных источника. Статус синхронизации и сообщения об ошибках можно найти в разделе Логи.

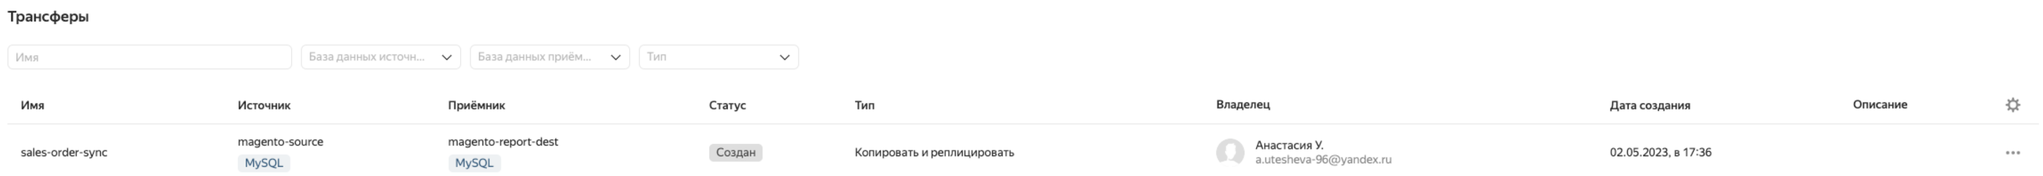

9. Проверим, что схемы базы данных появились в промежуточном хранилище:

   - Перейдите в раздел SQL стейджингового хранилища ya-sample-cloud-mysql.
   - Введите имя пользователя **yc-user** и пароль **12345678**.
   - Выберите БД magento-cloud.
   - Нажмите **Подключиться**.
   - В окне появится схема БД интернет-магазина.

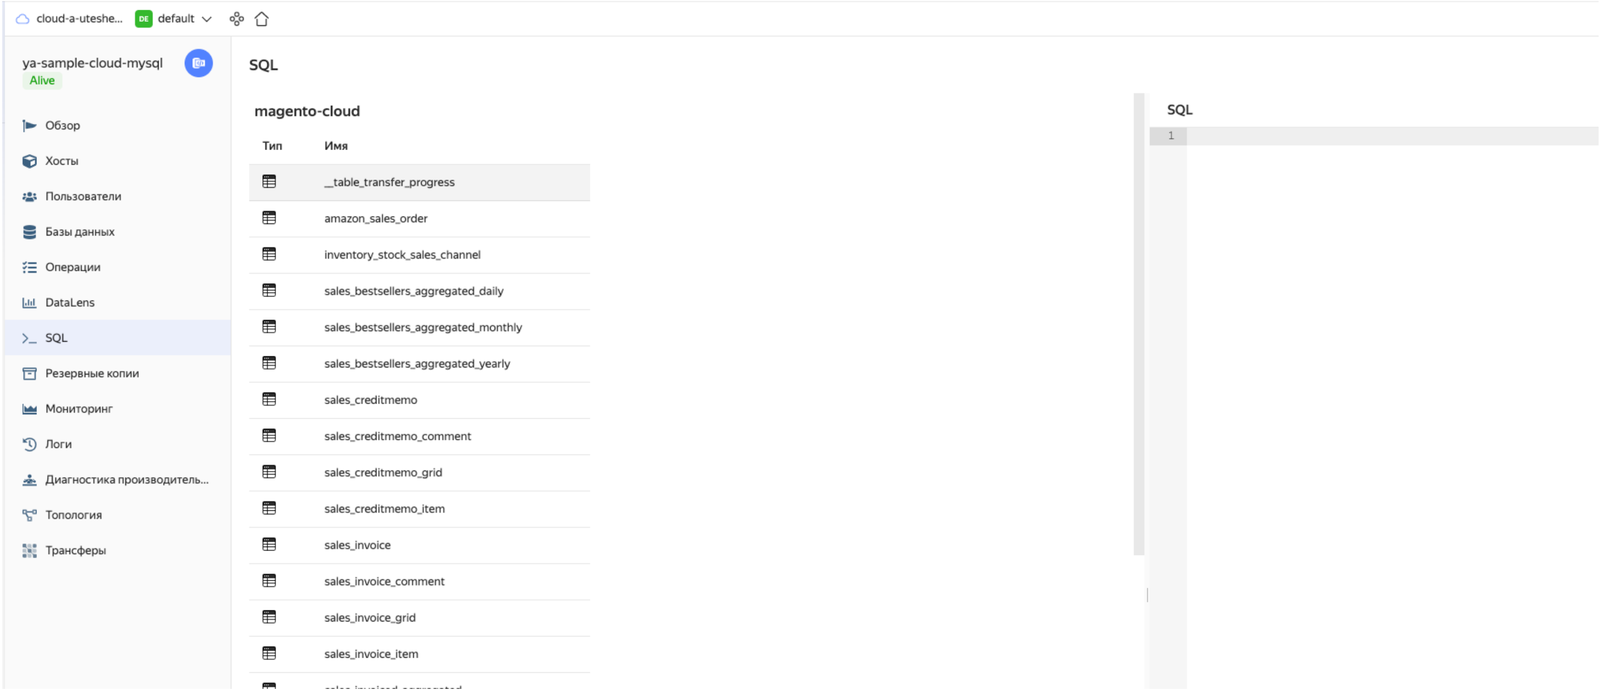

Импорт данных

Вот, что нужно сделать, чтобы импортировать данные из промежуточного хранилища MySQL в ClickHouse:

1. Создаем кластер ClickHouse. Указываем, что поддерживаться будет гибридное хранение на блочном диске и в облачном хранилище (Object Storage). Дополнительно ставим разрешение на доступ к Yandex DataLens — в нем мы потом будем строить аналитические отчеты.
2. Переходим к настройке MySQL. Создаем первую таблицу, в которую вносим данные об интернет-заказах из промежуточного хранилища посредством MySQL Engine. Причем выбираем только те колонки в таблице, которые нам потребуются для построения аналитических отчетов.
3. Затем создаем вторую таблицу уже в ClickHouse, в которой:
   - исключаем повторы записи при импорте данных через команду ReplacingMergeTree;
   - настраиваем жизненный цикл записи (TTL): по истечении этого времени данные автоматически станут архивными и переместятся в Object Storage.
4. Осталось выполнить SQL-запрос, который копирует данные из первой таблицы во вторую. В результате данные очищаются от повторов записей, разделяются на свежие и архивные и фактически материализуются в ClickHouse.

1. В консоли управления Yandex Cloud выберите **Managed Service for ClickHouse**. В правой верхней части страницы нажмите **Создать кластер**. Откроется страница с параметрами кластера ClickHouse:
   - В разделе **Базовые параметры** задайте имя кластера (в нашем примере *inventory)*.
   - В разделе **База данных** задайте имя БД и имя пользователя как *inventory*. Также задайте пароль для пользователя.
   - В разделе **Хосты** добавьте новый хост. Укажите зону доступности *ru-central1-a*. Если Вы планируете подключаться к кластеру через интернет, нажмите на иконку редактирования хоста и включите настройку «Публичный доступ». Нажмите **Сохранить** . Подробнее о создании кластера см. раздел документации «Создание ClickHouse-кластера».
   - В разделе «Дополнительные настройки» включите опции:
     - **Гибридное хранилище,**
     - **Доступ из DataLens,**
     - **Доступ из консоли управления,**
     - **Доступ из Метрики и AppMetrica,**
     - **Доступ из Serverless.**
2. Нажмите **Создать кластер**.

3. После создания кластера откройте DBeaver. В левом верхнем углу нажмите значок, чтобы создать соединение с источником данных. В открывшемся окне выберите тип **All** и нажмите на **ClickHouse**:

Укажите параметры:

- **Хост** кластера
- **Порт: 8443** (если вы настроили публичный доступ для нужного хоста) **8123** (если к хосту нет публичного доступа. Для подключения с таких виртуальных машин необязательно использовать SSL-соединение)
- **БД/Схема** — название БД. В нашем случае *inventory*
- **Пользователь**. В нашем случае *inventory*
- **Пароль** пользователя

Если вы настроили публичный доступ для нужного хоста, дополнительно нужно указать параметры SSL-соединения. Для этого перейдите на вкладку **Driver properties** и задайте параметры:

- **SSL:** *true*
- **sslmode:** *strict*
- **sslrootcert:** путь к файлу на диске с CA сертификатом Yandex. Скачать файл сертификата можно по ссылке: https://storage.yandexcloud.net/cloud-certs/CA.pem

Нажмите **Готово**, чтобы сохранить соединение. Во вкладке **Базы данных** появится БД с именем inventory:

Теперь можно создать связь с таблицей во внешней БД MySQL. Конфигурирование интеграционных таблиц осуществляется с помощью запросов CREATE TABLE или ALTER TABLE. Настроенная интеграция выглядит как обычная таблица, но запросы к ней передаются во внешнюю систему.

4. Нажмите на БД inventory. Чтобы открыть редактор SQL, на панели сверху выберите **SQL** → **Новый редактор SQL**.

5. В редакторе введите запрос на создание таблицы **mysql_sales_order_grid**:

```
CREATE TABLE mysql_sales_order_grid  (
`entity_id` UInt32,
`status` Nullable(String),
`store_id` Nullable(UInt16),
`store_name` Nullable(String),
`customer_id` Nullable(UInt32),
`grand_total` Nullable(Float32),
`order_currency_code` String,
`created_at` DateTime,
`updated_at` DateTime,
`billing_address` Nullable(String),
`shipping_address` Nullable(String),
`shipping_location` Nullable(String),
`shipping_information` Nullable(String),
`customer_email` Nullable(String),
`customer_group` Nullable(String)
)  ENGINE = MySQL('<my-yandex-cloud-cluster>.mdb.yandexcloud.net:3306', '<mysql-database-name>', 'sales_order_grid', '<mysql-user>', '<mysql-user-pwd>’);
```

В запросе замените:
<my-yandex-cloud-cluster> на хост кластера
<mysql-database-name> на имя БД
<mysql-user> на имя пользователя
<mysql-user-pwd> на пароль пользователя

6. Чтобы посмотреть содержимое созданной страницы, отправьте запрос:

```
select * from mysql_sales_order_grid;
```

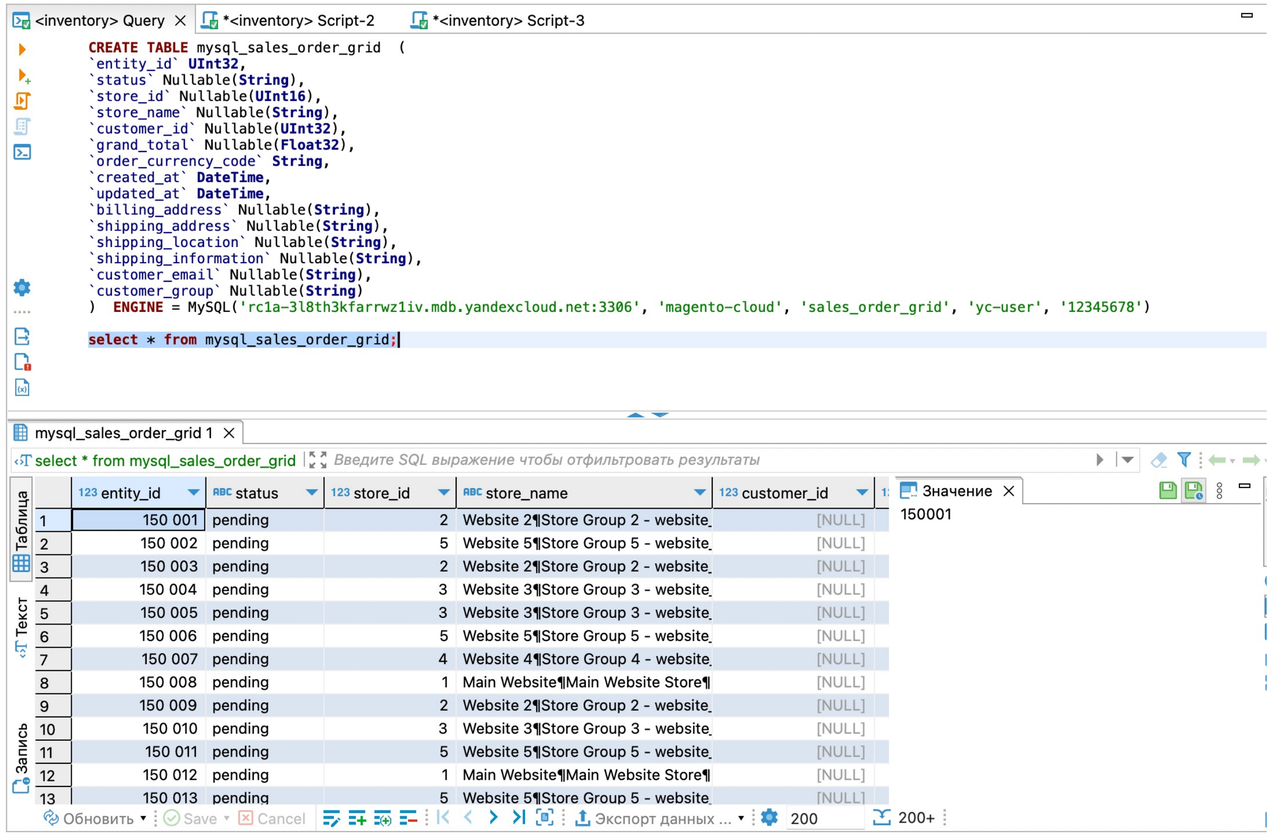

	123 entity_id	ABC status	123 store_id	ABC store_name	123 customer_id
1	150 001	pending	2	Website 2¶Store Group 2 - website	[NULL]
2	150 002	pending	5	Website 5¶Store Group 5 - website	[NULL]
3	150 003	pending	2	Website 2¶Store Group 2 - website	[NULL]
4	150 004	pending	3	Website 3¶Store Group 3 - website	[NULL]
5	150 005	pending	3	Website 3¶Store Group 3 - website	[NULL]
6	150 006	pending	5	Website 5¶Store Group 5 - website	[NULL]
7	150 007	pending	4	Website 4¶Store Group 4 - website	[NULL]
8	150 008	pending	1	Main Website¶Main Website Store¶	[NULL]
9	150 009	pending	2	Website 2¶Store Group 2 - website	[NULL]
10	150 010	pending	3	Website 3¶Store Group 3 - website	[NULL]
11	150 011	pending	5	Website 5¶Store Group 5 - website	[NULL]
12	150 012	pending	1	Main Website¶Main Website Store¶	[NULL]
13	150 013	pending	5	Website 5¶Store Group 5 - website	[NULL]

7. Далее отправьте запрос на создание таблицы sales_order:

```
CREATE TABLE sales_order(
entity_id UInt32,
status Nullable(String),
store_id Nullable(UInt16),
store_name Nullable(String),
customer_id Nullable(UInt32),
grand_total Nullable(Float32),
order_currency_code String,
created_at DateTime,
updated_at DateTime,
billing_address Nullable(String),
shipping_address Nullable(String),
shipping_information Nullable(String),
customer_email Nullable(String),
customer_group Nullable(String),
shipping_location Nullable(String)
) ENGINE = ReplacingMergeTree() --
PARTITION BY toYYYYMM(created_at)
ORDER BY (entity_id)
TTL created_at + INTERVAL 1 MONTH TO DISK 'object_storage’;
```

ReplacingMergeTree позволяет исключить дубликаты записей.
TTL (Time to Live) указывает, что через месяц после создания записи она будет перенесена в Yandex Object Storage в системный раздел S3.

8. Выполните запрос, который копирует данные из таблицы mysql_sales_order_grid в таблицу sales_order.

   INSERT INTO inventory.sales_order (entity_id, status, store_id, store_name, customer_id, grand_total, order_currency_code, created_at, updated_at, billing_address, shipping_address, shipping_location, shipping_information, customer_email, customer_group) SELECT entity_id, status, store_id, store_name, customer_id, grand_total, order_currency_code, created_at, updated_at, billing_address, shipping_address, shipping_location, shipping_information, customer_email, customer_group FROM mysql_sales_order_grid WHERE entity_id > (SELECT MAX(entity_id) from sales_order);

   Чтобы посмотреть содержимое страницы sales_order, отправьте запрос:

   select * from sales_order so;

   Чтобы оценить объем данных, который находится на сетевых дисках и в Object Storage, отправьте еще один запрос:

   SELECT * FROM system.disks;

   В ответе вы должны получить информацию об используемом пространстве кластера ClickHouse с гибридным хранилищем:

Импорт данных

Мы реализовали гибридное хранилище: часто используемые данные хранятся в кластере Managed Service for ClickHouse, а архивные данные — в Yandex Object Storage.

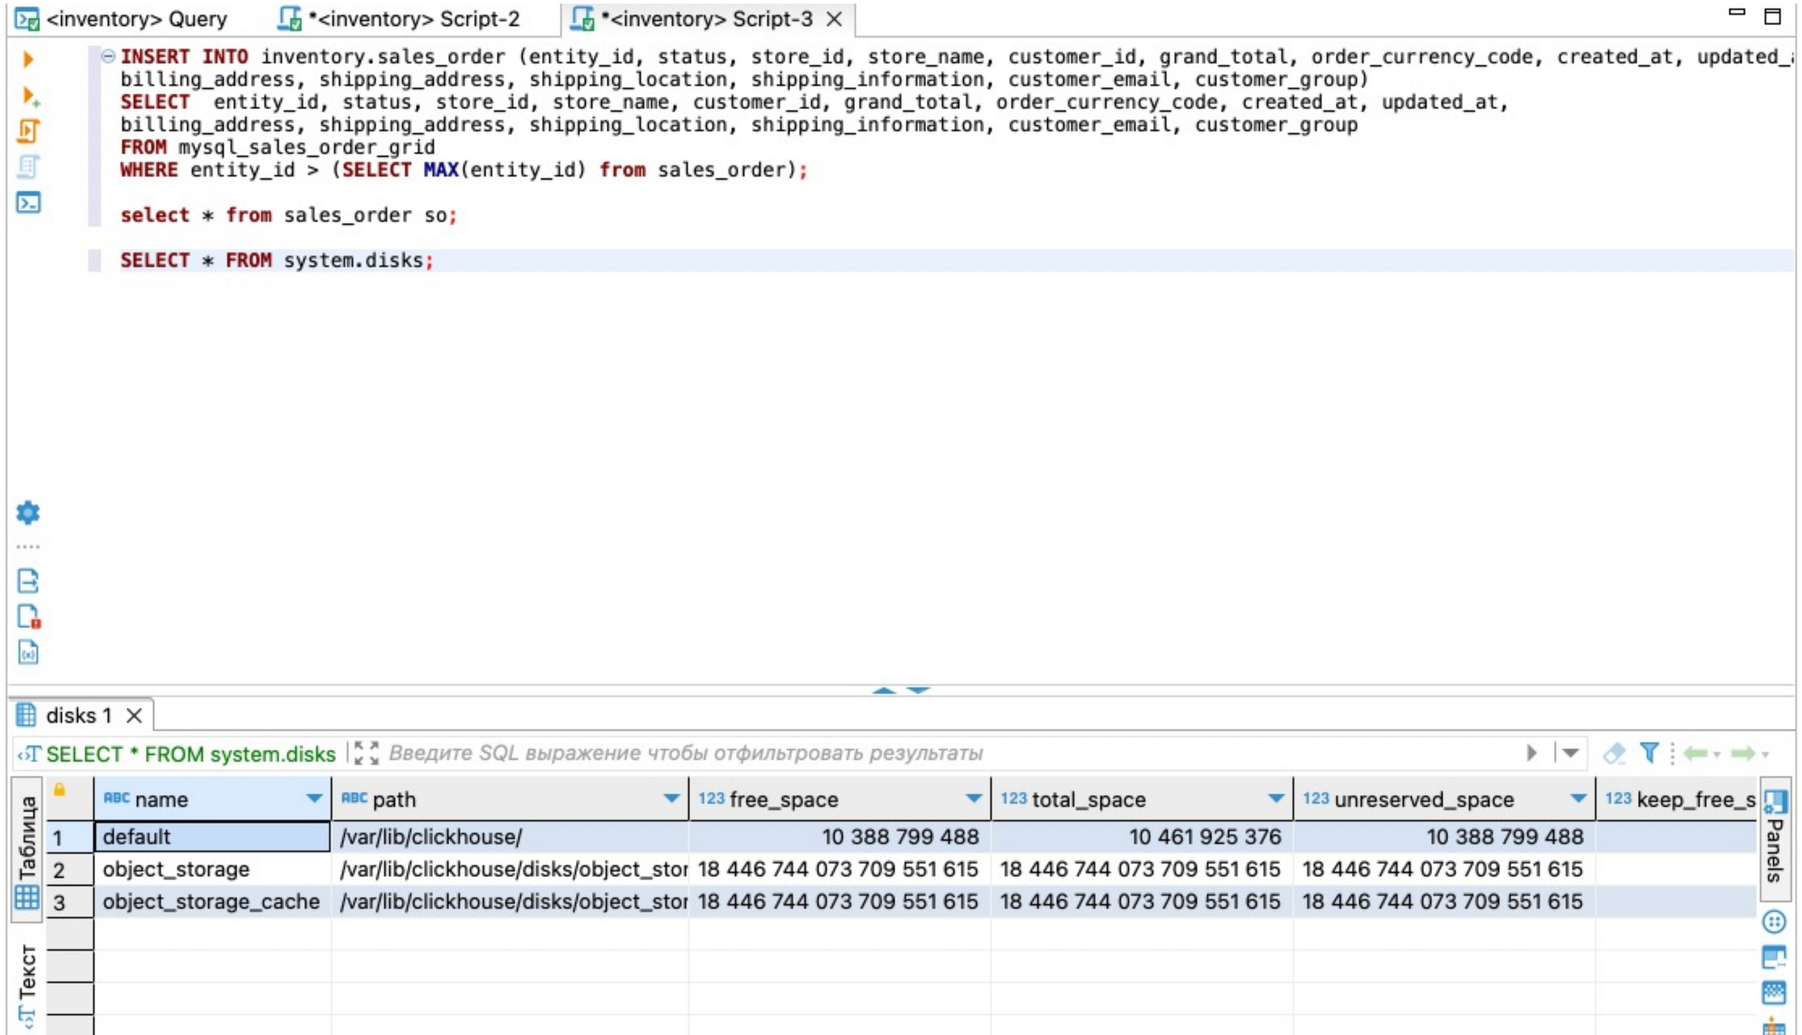

Визуализация

1. На главной странице DataLens нажмите Создать подключение и выберите тип ClickHouse. Откроется страница с параметрами подключения. Укажите параметры:

   - Название подключения может быть произвольным
   - Кластер, в котором находится источник данных
   - Имя хоста
   - Имя пользователя
   - Пароль пользователя

2. Включите опцию **Разрешить использование подзапросов в качестве источника** и нажмите **Проверить подключение.**
   Если проверка прошла без ошибок, сохраните подключение: в правом верхнем углу нажмите **Создать**.
   Теперь у нас есть доступ к источнику данных, на основе которого можно создать датасет.

3. В правом верхнем углу **нажмите Создать датасет.**
4. Перенесите на рабочую область таблицу Inventory.mysql.sales_order_grid

5. Скорректируем поля таблиц. В левой части страницы над подключениями нажмите на вкладку **Поля**. Откроется страница с полями таблиц. Внесите некоторые изменения:

- Для поля **store_location** и **shipping_location** измените тип данных на **Геоточка**
- В столбце **Агрегация** для поля **grand_total** выберите **Сумма**.
- Продублируйте поле **entity_id**. Нажмите на значок и выберите **Продублировать:**
- Переименуйте дубликат в **store_orders**: нажмите имя строки, удалите текущее имя и введите новое.
- В столбце **Агрегация** для поля **store_orders** выберите **Количество уникальных**.
- Аналогично шагу 3 продублируйте поле **customer_id**, переименуйте дубликат в **store_customer** и выберите **Количество уникальных** в столбце **Агрегация**.
- Поменяйте тип поля **create_at** с **Дата и время** на **Дата.**

6. В правом верхнем углу нажмите **Создать**, чтобы указать имя датасета и сохранить его. Всё готово для визуализации данных с помощью чартов.

7. Для примера нам понадобится два типа чартов:
   Карта, на которой отобразим точки заказов.
   Нормированная диаграмма с областями, которая будет показывать динамику отгрузок.
   В правом верхнем углу нажмите **Создать чарт**. Выберите тип чарта **Карта**:
8. Создадим новый слой, на котором будут отображаться точки заказов. Справа от слоя нажмите значок “+”, чтобы добавить новый слой. Переименуйте его в **Заказы**. Чтобы отобразить точки заказов, добавьте измерение **shipping_location** в секцию **Геоточки**.
9. Точек заказов достаточно много, поэтому будет удобно отслеживать количество заказов с помощью тепловой карты. Нажмите на секцию **Геоточки** и выберите **Геоточки (тепловая карта)**:
10. Для возможности фильтровать чарт по временному периоду добавьте измерение **created_at** в секцию **Общие фильтры**. В открывшемся окне выберите пресет **Последние 365 дней** и нажмите **Применить фильтр**.
    Первый чарт готов. В правом верхнем углу нажмите **Сохранить**, чтобы указать имя чарта и сохранить его.

11. Создадим второй чарт для динамики отгрузок:
    - Измените тип текущего чарта на **Нормированная диаграмма с областями**.
    - Добавьте измерение **created_at** в секцию **X**. По горизонтали будут отображаться даты отгрузки.
    - Добавьте показатель **store_orders** в секцию **Y**. По вертикали будет отображаться количество заказов.
    - Добавьте измерение **store_name** в секцию **Цвета**. График каждого магазина будет выделен своим цветом.

12. В верхнем правом углу нажмите значок галочки рядом с кнопкой Сохранить и выберите Сохранить как. В открывшемся окне укажите имя нового чарта и нажмите кнопку **Сохранить**.
13. Создайте дашборд и разместите оба чарта на нем.
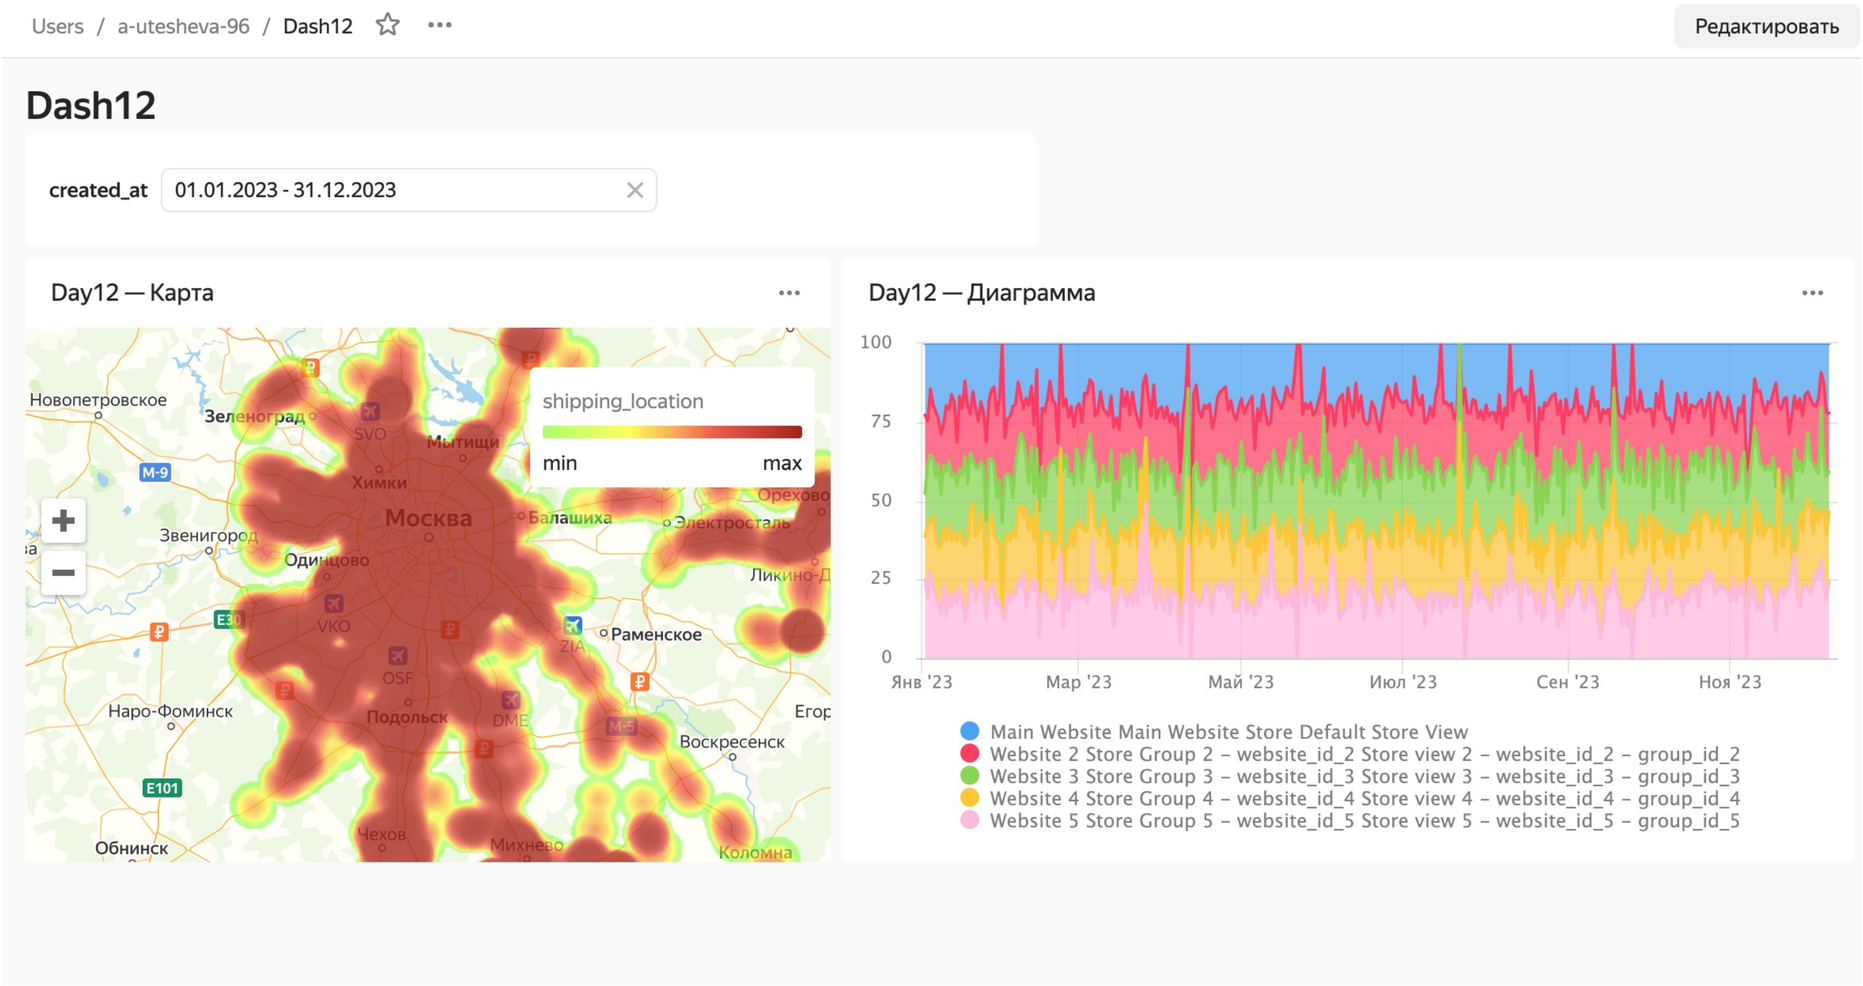
Визуализация